IanParedesVázquez

Q-Learning y Cliff Walking

Instrucciones de ejecución

El código fue desarrollado en el archivo solucion.py. Utiliza la librería estándar de Python, por lo que no es necesario instalar dependencias extras. Para ejecutar el entrenamiento y generar el archivo de reporte estadístico, corra el siguiente comando: *python solucion.py*

Al terminar, el programa mostrará en consola el valor del retorno obtenido por el agente y guardará un archivo llamado recompensas.csv con los datos de aprendizaje por episodio.

Cuestionario

- **¿Por qué el camino de 13 pasos resulta ser el óptimo?** En este entorno, cualquier movimiento válido tiene una penalización de -1, mientras que caer al precipicio cuesta -100. La ruta más segura que rodea la zona de peligro requiere exactamente 13 desplazamientos (1 hacia arriba, 11 hacia la derecha y 1 hacia abajo). Por lo tanto, el máximo puntaje posible que se puede alcanzar sin sufrir la penalización del acantilado es -13.
- **¿A qué se debe que la curva de entrenamiento esté frecuentemente por debajo de -13?** Esto ocurre por la mecánica de exploración del algoritmo. Al tener el parámetro ϵ configurado en 0.1, el agente tiene un 10% de probabilidad de ignorar lo aprendido y moverse aleatoriamente. En un mapa donde casi todo el borde inferior es un acantilado, esos movimientos aleatorios suelen resultar en caídas frecuentes durante el entrenamiento, bajando el puntaje. El retorno óptimo de -13 solo se garantiza al evaluar la política puramente ambiciosa (greedy), donde la exploración se apaga por completo.
- **¿Cómo funciona la transición y la ecuación cuando el agente cae por el borde?** Caer al precipicio no da por terminado el episodio. El agente recibe su castigo de -100 pero es teletransportado de regreso a la coordenada de inicio (3,0). Debido a esto, al aplicar la actualización de Q-learning, el estado futuro que se evalúa es el inicio, incorporando el valor máximo de sus posibles acciones. El valor futuro solo se reemplaza por un cero definitivo cuando el agente pisa la casilla de la Meta, ya que ese es el único estado realmente terminal.